


Data Analyst & Financial Domain

전혜연

전산세무 1급/2급
전산회계 1급/2급
ERP정보관리사(회계)
010-9895-8092
amyshare27@gmail.com



Skills & Tools



Education & Awards

학 력	• 한국방송통신대학교 경영학 학사
교육이수	• 유비온디지털교육센터 KDT 빅데이터를 활용한 디지털 금융 전문가 과정 수료 • 이수직업전문학교 세무회계 실무과정 수료
수 상	• KDT 과정 - 프로젝트 우수상

Professional Summary

"회계 도메인 지식을 데이터 분석으로 확장해 기업의 의사결정을 지원합니다."

세무 실무(재무제표 작성·해석·분석·부실기업 판별·세무조사)에서 축적한 도메인 지식과 Python 기반 데이터 분석 역량을 결합해, 기업의 이상 징후를 식별하고 실무에 활용 가능한 인사이트를 도출하는 데이터 분석가입니다.

산업구조 전환기 비상장 외감 제조업의 한계기업 조기예측 (EWS)

01 프로젝트 개요

02 핵심 개념 정의

03 연구 설계 및 프레임워크

04 데이터 구축 및 전처리

05 EDA

06 변수 설계 및 통계검증

07 모델링전략 (탐색)

08 모델링전략 (선택)

09 모델링성능 (검증)

10 설명 가능한 AI (SHAP)

11 핵심발견 및 활용방안

12 한계 및 향후과제

 **프로젝트 요약** (2025.05 ~ 2025.06)

(단독 프로젝트(기획~ 검증 전 과정 수행) | 데이터: TS2000 + KICOX + ECOS/KOMIS)

비즈니스 문제	비상장 외감 제조기업의 한계기업 조기 탐지 및 선제적 리스크 관리
분석 기법	ML 기반 EWS 구축 (XGBoost SMOTE, SHAP 기반 변수 해석)
핵심 차별점	도메인 기반 하이브리드(재무·산업·공간) 모델 설계 및 한계기업 2년 전 조기 탐지

 **비상장 외감 제조업 선정 이유**

- 제조업 구조전환 심화
자본집약도·원재료의존도 등 전환신호 악화 → 한계기업 진입확률 ↑
- 부실 전이 경로
산단 내 한계기업 밀도↑ → 인접기업 한계기업 진입확률↑ → 상관관계 규명
- 정보비대칭 해소 (재무데이터 부재)
소상공인 생태계 선행지표 발굴: 비상장 외감 기반, 기존모형(Altman·Ohlson·M-Score) 변수 통합, 조기 포착 확장

 **Domain Expertise**

- 한계기업 정의 (한국은행·KDB산업은행 : 한계기업 선별 기준 차용)
ICR(이자보상배율) 1 미만 3년 연속 → (Y=1) 레이블 · 코호트 설계
(De Martiis et al. (2025), Zombie Firm EWS 방법론 참고)
- 구조적 변수 설계
산업구조(기계화집약도 등) + 공간 특성(계획입지여부·산단 내 한계기업 밀도) 데이터화
- 재무비율 이상 징후 해석
도메인 경력 → 재무 이상 패턴 정의 · 변수 타당성 검증

 **AI-Human Collaboration**

- Human → 도메인설계 (도메인 기반 문제 정의 · 변수 설계 · 결과해석)
- AI → 기술 구현 (통계 1개 + ML 4개 + DL 2개 · SHAP 기반 변수 해석 · 전 과정 단독 수행)
- RAG → 기술융합 (RAG + 생성형 AI 결합 → 정책 정보 연동 모니터링 대시보드 구현)
- End to End → 비개발자 경력을 AI 협업으로 돌파 → 실무급 EWS 단독 완주
- 도메인→ 방향 / AI → 실행가속 / 반복 실험 → 구조적 일관성

프로젝트 진행 프로세스

진행기간 : 2026.05 ~ 2026.06 프로젝트 구성인원 : 1인(단독프로젝트, 전 과정 단독 수행)

단계	요약	스킬 . 툴	판단 근거
문제정의	- 수도권 계획입지(지식산업단지) 공실 심화를 목격하며, 4차산업 전환기 제조업 위기의 구조적 신호로 판단 - ICR<1 최초 진입 시점을 기준으로 제조업 한계기업 코호트 구성 -> 동일 출발선에서 회복/고착화 여부를 t+2 시점에 비교 재무제표만으로는 안 보이는 위기 이후 분화(회복 vs 고착화)를 산업·공간 구조 요인과 함께 조기에측하는 문제로 정의	Notion	- 지식산업단지 공실은 단순 부동산 문제가 아닌 산업구조 전환에 적응 못한 제조업의 신호라고 해석 재무비율만으로는 위기 이후 "회복"과 "고착화"를 구분하기 어렵다고 판단-> 산업·공간(입지) 요인을 함께 봐야 한다는 가설 수립 - 예측 시계를 위기 진입 후 1~2년(t+2)으로 설정해, 실무적 개입(구조조정 지원 등)이 가능한 시점 확보
데이터 수집 및 전처리	- TS2000·KICOX·거시경제데이터를 산업단지 매핑으로 결합, - 결측치·이상치 정제 후 ICR<1 최초진입 코호트 구성	- Python (pandas, NumPy) - Kakao developers	- pandas, NumPy: 결측치는 업종·연도별 중앙값 대체, 산단 미매칭은 개별입지로 0 대체, 이상치 -> 상하위 1% Clipping - scikit-learn: RobustScaler로 Train 기준 스케일링, BorderlineSMOTE로 Train Only 불균형 보정 - kakao developers: 산업단지 주소 지오코딩 및 11단계 정규화로 기업-산단 매칭(성공률 75.3%)
변수설계 및 레이블	3-Layer 파생변수(재무/구조전환/공간통제) 설계 - ICR<1 3년 연속 여부로 Y 레이블 생성	Python (pandas, NumPy, SciPy, statsmodels)	핵심 판단: 재무비율만으로는 회복/고착화 두 집단이 거의 구분되지 않음 확인 위기 기업이라도 "재무·산업구조전환·공간통제"가 생존을 가른다는 가설 수립 - pandas, NumPy: 파생변수 등 계산 및 ICR<1 3년 연속 여부로 Y 레이블 생성 - SciPy, statsmodels: 계획입지여부 등 변수의 통계적 유의성 검정 - t+2 라벨: 3개년 연속 조건 완성 + 공간변수 효과 발현 시간 확보
모델링	ML·DL 여러 모델 비교, 앙상블 시도 후 단독 XGBoost 최종 채택	Python (scikit-learn, PyTorch)	- scikit-learn: ML 모델(LR·RF·XGBoost·LGBM·CatBoost) 비교 실험 - PyTorch: DL 모델(TabNet·MLP) 비교 실험 - 앙상블(Soft/Weighted Voting, Stacking)도 시도, 단독모델보다 성능이 낮아 최종 배제 - 불균형(양성 7.6%) 구조상 Recall 중심으로 최종 XGBoost 채택
검증	- 연도 구간별 분할 후 회사코드 기준 그룹 정렬로 데이터 누수 방지 - 비모수 검정으로 결과 검증	Python (scikit-learn, SciPy, statsmodels)	- scikit-learn: 연도 구간(Train 2010~2017·Val 2018~2019·Test 2020~2022·OOS 2023)으로 먼저 분할, 그 안에서 회사코드가 겹치지 않도록 그룹 정렬해 데이터 누수 방지 - SciPy, statsmodels: 정규성·등분산성 위반 확인 후 t-검정 대신 비모수 검정으로 전환 - 그룹 간 차이는 신뢰구간이 겹치면 유의하지 않다고 보수적으로 판단
결과 및 시각화	- 지도·차트 기반 대시보드로 결과 구현(SHAP해석) - 정책기관·지자체·금융기관 대상 활용방안 제시	Python (matplotlib, seaborn, plotly, Dash)	- Dash로 전체 지도(클릭 시 지역 드릴다운) + 도넛차트·막대그래프 + 정책자료 벡터DB 연동 대시보드 구성 - SHAP로 모델이 어떤 변수를 중요하게 봤는지 해석 정책기관(조기경보)·지자체(고용안전망)·금융기관(대출심사) 등 활용처별 적용방안 제시 - 예측 시점 이후 실제 발생한 데이터(2023 코호트)로 검증

POINT 01 산업구조 전환기

- 메가트렌드
기술·디지털·탈탄소·인구구조·국제정세
- 부실 경로
생산구조 변화 → 전통업종 수익성·회전율 저하 → 만성부실·한계기업화
- 진단 솔루션
산업구조 역동성 진단 → 재무·공간·산업구조 결합 복합지표 필요

POINT 02 계획입지 vs 개별입지


- 계획입지(산업단지): 인프라·집적효과 선제확보
(국가·일반·농공·도시·노후·스마트 유형)
- 개별입지(개별공장): 인프라 혜택 부재 및 부대비용 부담
(산업단지 밖 자유 설립)

POINT 03 코호트 정의 & 레이블 정의

- 코호트: 3년 연속 ICR 1 미만 기업
- 생존편향 차단: 최초 진입 시점 데이터만 사용
- 레이블: Y=1(3년 연속 부실 유지), Y=0(정상 유지 또는 회복)

POINT 04 산업구조 × 공간 × 코호트 -> 문제 재정의

- 한계 : 기존 연구의 산업전환 또는 공간정보 단독 분석
- 본 프로젝트 : 산업전환 · 공간 신호 + 코호트 결합 분석
→ 전환기 충격이 더 크게 나타나는 지점 동시 포착
- 가치 : 재무지표 이면의 구조적 부실 전이 경로 포착



외감 제조기업(코호트)

11,875개사

기업-연도 단위 관측치 수

157,541건

분석 기간

2009~2023

(2009년 전기 대비 파생변수 계산 lag 기준연도, 코호트 관측기간은 2010~2023)



데이터 출처

TS 2000

재무데이터

KICOX , FACTORY ON

산업단지 및 개별입지 정보

ECOS, KOMIS

거시경제 및 원자재



Data Pipeline

①

TS 2000 수집

②

산업단지매핑

(Kakao API)

③

거시경제결합

④

기초통계량

⑤

결측치처리

⑥

이상치처리

(Winsorizing)

⑦

파생변수 생성

⑧

ICR<1 최초 진입

(코호트 구성)

⑨

시계열분할

(Train/val/test/oos)



공간정보 구축



- 산업단지 주소 DB 구축
- 11단계 주소 정규화
- Kakao API 좌표 변환
- 기업-산단 매칭

매핑성공률

75.3%

도메인 지식으로 구조를 설계하고, AI로 데이터 구축을 구현

클래스 불균형 (코호트 기준)



한계기업 클래스 불균형


- 한계기업 비중
 - 한계기업(Y=1) 비중 28.4% → 클래스 불균형 존재
- ACC 필터 평가
 - ACC 0.6 이상 1차 필터 → Recall · F2 · AUC 순서 우선 평가
- 불균형 데이터 평가
 - 불균형 데이터 특성상 ACC만으로는 한계기업 탐지력 평가 불가
 - PR-AUC 기반 불균형 대응 평가체계 적용 타당

👉 모델링은 Accuracy 문제가 아니라 비용 민감 문제로 정의됨

입지 유형 구조

- 전체 외감 제조업
 - 계획입지: 집적효과·공유 인프라로 부실 위기 시 회복 탄력성 존재 가능성
 - 개별입지: 입지 자율성 높으나 인프라 혜택 부재로 비용 부담
- 비율
 - 계획입지 비율: 75.3%
 - 개별입지 비율: 24.7%

👉 한계기업 조기에측을 위한 공간(입지) 변수 확보



Layer1

재무 62개

Layer2

산업 8개


Layer3

공간 11개

Layer4

거시 10개
(최종모델제외)

변수 선택 요약 (25 / 81 · 최종 25개 변수 선정 (30.9%))



분포검증

- 정규성, 등분산성 위배
- t-검정 대신 강건한 보정 필요



1차 통제정제

- 등분산성 위배
→ 분산·자유도 보정 채택
- $N > 30$ 중심극한정리로 정규성 위배에도 강건
- 1차 노이즈 필터링



2차 심층정제

- 81 → 76
(분산0·상관계수 제거)
- 76 → 35
(Welch t-test)
- 35 → 25
(VIF·Lasso·SHAP)



최종 변수 선정

- 통계적 유의성 ($p < 0.05$, $VIF < 10$)
- 도메인 타당성 (선행연구 기반)
- 모델 기여도 (SHAP, 피처인포턴스 상위)

• 1차 통계적 필터링 (81→35) ★ 1차 모델링: 35개

- 분산0 · 상관계수 0.95 ↑ 제거 (81→76)
- Welch T-test ($p < 0.05$) 축소 (76 → 35)
- 중복변수 제거
- 논문·선행연구 근거 편입
- VIF · Lasso 정규화 정제

• 2차 이론·XAI 정제 (35→25) ★ 2차 모델링: 25개

SHAP 기반 하위 10개 제거 → 최종 25개

1차 모델링 입력
35개 변수

클래스 불균형 처리
SMOTE 1:1 · CT-GAN 1:1



1차 모델링
LR + ML 4개 + DL 2개 · OPTUNA N=50

SHAP 변수 정제
35개 → 25개

2차 모델링
LR + ML 4개 + OPTUNA N=50

앙상블
SOFT · WEIGHTED · STACKING


최종 선정
XGBOOST + SMOTE · THRES 0.48



ACC 0.6 이상 1차 필터 → RECALL·F2 손실 최소화 기준 → XGBOOST + SMOTE · THRES 0.48 최종 선정

• ACC 0.6 이상 통과 모델 · 평가 기준: Recall → F2 → AUC

모델	Acc	Recall	F2	AUC
XGBoost (SMOTE)	0.621	0.633	0.571	0.676
Soft Voting	0.623	0.618	0.562	0.676
Weighted Voting	0.622	0.620	0.562	0.676
Stacking	0.657	0.550	0.524	0.669





- Soft/Weighted/Stacking → Recall↓ F2↓ · 탐지력 감소
- XGBoost → Recall·F2 균형 최적 · 최종 선택


- Recall · F2 trade-off 기반 → XGBoost + SMOTE 단독 모델 최종 선정
- 모델의 민감도(Recall) 유지 및 운영 직관성 확보
- 부실 전이 방지를 위한 리스크 탐지 최적화 모델

검증 기준 : XGBoost + SMOTE · Threshold 0.480 · OOS 2023년 (819개사)

Dataset	Thres	Acc	Preci	Recall	F1	F2	AUC
Val	0.475	0.627	0.323	0.554	0.408	0.485	0.657
Test	0.475	0.592	0.410	0.560	0.473	0.522	0.625
Val	0.480	0.639	0.330	0.539	0.409	0.478	0.657
Test	0.480	0.601	0.416	0.549	0.473	0.516	0.625
Val	0.485	0.656	0.342	0.521	0.413	0.472	0.657
Test	0.485	0.615	0.430	0.541	0.479	0.515	0.625
Val	0.490	0.666	0.347	0.499	0.409	0.459	0.657
Test	0.490	0.622	0.434	0.519	0.473	0.499	0.625




- 한계기업 미탐지(FN)의 실무 비용이 오탐(FP)보다 큼 → Recall 중심 threshold 0.48
- 미탐지(FN) : 한계기업 방치 → 연쇄도산
- 오탐(FP) : 정상기업 모니터링 → 불필요한 비용
- ※ 분석의 엄밀성을 위해 집단별 차이에 대한 통계적 검증(카이제곱, 피셔검증)을 병행 (상세: 원본 연구자료 참조)
- ※ OOS(2023) Y레이블은 2024~2025 실측 ICR로 확정 (상세: 원본 연구자료 참조)




XGB SMOTE SHAP Summary Plot
(OOS 기준)

OOS 2023 · XGBOOST SMOTE ·
25개 변수 기준



변수 중요도 상위 10개

총자산·수익성·운전자본
세무·분석 경험이 짙어낸 핵심 생존 변수



입지유형별 / 자산규모별

계획입지 44.1% VS 개별입지 30.4%
(중소 규모, $X^2=3.56$, $P=0.059$)
공간 위치가 재무 외 위험 신호로 작동

참고 : 중대 규모 방향 반전 (개별입지 45.0%, $P=0.040$)

재무변수가 아닌 '기업의 구조적 위치'가 한계기업을 설명한다.



정책기관)

- EWS 기반 산단 입주기업 위험등급 분류 · 조기 경보 발령

금융기관)

- 한계기업 진입 2년 전 탐지 기업 우선 지원 대상 선정

지방자치단체)

- 산단 내 한계기업밀도 모니터링
→ 집단 부실 선제 감지

금융기관)

- 모델 예측 확률값 기반 신용위험 보완 지표 제공

정책기관)


- SHAP 기여도 기반 취약기업 리스트 자동 추출 · 구조조정 대상 선별

지방자치단체)

- 산단 단위 실시간 모니터링 대시보드 · 고용안전망 연계

핵심 발견(경향)

- 계획입지 기업 한계기업 진입률 44% vs 개별입지 30% ($\chi^2=3.56$, $p=0.059$, 경계선 유의)
- 중소 규모 산단 입주기업 : 총자산↑ + 수익성↓ 패턴에서 위험 집중
- 산업구조 전환기 충격이 계획입지 집적 기업에 더 크게 작용



조기탐지 → 선제개입 → 연쇄부실 차단 구조 설계

변수 확장 관련 한계

- 계획입지·개별입지 이분화에 그침

-> 노후·스마트·일반 산단 유형별 세분화는 후속 과제

- Layer 4 거시변수(금리·경기사이클 등) 미반영

→ 정합성 검증 후 모델 고도화 예정

분석 집단의 범위 한계

- 현재 코호트(제조업 입지 외감기업) 한정

→ 전체 비상장 외감 제조업으로 확장 시 공간적 분포 패턴 강건성 추가 검증 필요

실용화 측면

- 대시보드 현재 집단 수준 예측

→ 개별 기업 단위 드릴다운 조회 기능 고도화 후 실무 적용 추진

한계기업은 '이미 무너진 기업'이 아니라 '아직 개입 가능한 기업'입니다.
도메인을 이해하는 분석은 숫자에 의미를 더해 의사결정을 위한 인사이트를 만듭니다.